

國立虎尾科技大學 自動化工程系

車充用穩壓 IC 黏著瑕疵檢測之研究

指導老師：李廣齊
學生：邱苡軒

中華民國 114 年 7 月 23 日

目錄

摘要	4
第一章 緒論	5
1-1 研究目的	5
1-2 研究背景	5
1-3 研究方法	6
1-4 論文大綱	7
第二章 穩壓 IC 焊點影像資料與瑕疵分析	8
2-1 車充用穩壓 IC 焊點應用背景	8
2-2 影像資料來源與說明	11
2-3 瑕疵類型定義	12
2-4 焊點影像資料集建構方法	14
第三章 基於 YOLOv11 的穩壓 IC 焊點瑕疵辨識方法	16
3-1 系統流程與整體架構	16
3-2 焊點影像生成與前處理	17
3-2-1 接腳區域定位與焊點影像生成	17
3-2-2 接腳裁切與焊點影像生成	18
3-2-3 影像標準化與方向統一	18
3-2-4 訓練/驗證/測試資料切分策略	19
3-3 焊點瑕疵分類模型設計	20
3-3-1 模型架構選用	20
3-3-2 焊點分類任務定義	20
3-4 模型訓練策略與參數設計	21
3-4-1 模型版本比較設計	21
3-4-2 訓練參數組合設計	22
3-4-3 學習率調整策略設計	23
3-4-4 最終模型選擇準則	23
3-5 模型效能評估方法	24
3-5-1 分類評估指標	24
3-5-2 混淆矩陣分析方法	25
3-5-3 IC 層級判定規則 (8 腳整合)	25
第四章 實驗結果與分析	27
4-1 模型參數實驗結果分析	27
4-1-1 模型比較之結果	27
4-1-2 參數組合之結果分析	28
4-1-3 候選模型與最佳參數設定	29
4-2 焊點層級分類模型效能分析	30

4-2-1 焊點層級整體分類效能分析-----	30
4-2-2 各類別分類效能分析-----	31
4-2-3 混淆矩陣結果分析-----	32
4-2-4 測試情境設計與資料規模設定-----	32
4-3 IC 層級瑕疵判定結果-----	33
4-3-1 IC 層級判定示意-----	34
4-3-2 IC 層級判定結果與模型效能比較-----	36
4-3-3 IC 誤判案例與原因分析-----	36
4-4 綜合討論-----	38
4-4-1 模型效能整體分析-----	38
4-4-2 焊點層級與 IC 層級結果比較分析-----	39
4-4-3 不同測試規模之穩定性分析-----	40
4-4-4 模型差異與穩定性討論-----	41
4-4-5 實務應用可行性分析-----	41
第五章 結論-----	43
參考文獻-----	45

車充用穩壓 IC 黏著瑕疵檢測之研究

學生：邱苡軒

指導教授：李廣齊

國立虎尾科技大學自動化工程系碩士班

摘要

隨著智慧製造技術與晶片封裝產業不斷演進，自動光學檢測（Automated Optical Inspection, AOI）於電子製造流程中的重要性日益提升，並廣泛應用於產品品質管控與產線檢測作業。過去仰賴人工目視方式進行檢驗，不僅容易因檢測人員判讀差異而造成結果不穩定，長時間作業亦可能影響整體效率與生產成本。此外，以傳統規則建立之影像分析方法，在面對多樣化焊點異常情況時，通常缺乏足夠彈性，因此較難符合智慧製造環境對高精度檢測之要求。

本研究以車用充電穩壓 IC 焊點異常辨識為核心，建構一套以深度學習為基礎之檢測與判讀架構。研究中利用 YOLO（You Only Look Once）模型執行焊點區域定位以及缺陷辨識，並以單一焊腳（pin-level）作為資料分析單位，建立包含正常、少錫、冷焊、多錫、偏移以及其他異常等六種類別之焊點影像資料集。藉由不同模型尺寸與訓練設定條件之實驗分析，可發現 YOLOv11m 於焊點瑕疵檢測任務中具有較佳之整體效能與模型穩定度。

在 IC 層級檢測部分，本研究進一步將同一顆 IC 之八個焊腳辨識結果進行彙整，並依據實際產線檢測概念，採用「任一焊腳出現異常即判定該 IC 為不良品」之方式進行整體判讀，以貼近 AOI 設備於實務上的運作模式。研究結果顯示，YOLOv11m 除了在焊腳分類方面具有良好辨識能力外，在 IC 整體判定上亦能有效提升缺陷攔截效果。進一步分析可知，錯誤來源主要來自個別焊腳辨識誤差累積，而非 IC 層級判定機制本身失效。整體而言，本研究所提出之方法於實際 AOI 檢測應用中具備良好實用性與可靠度，可提供半導體封裝焊點智慧化檢測技術之研究參考。

關鍵字：自動光學檢測（AOI）、深度學習、焊點瑕疵檢測、智慧製造

第一章 緒論

1-1 研究目的

隨著電子製造產業持續邁向自動化發展，產品品質檢測已成為製程中不可或缺之關鍵技術。透過導入深度學習影像辨識技術，可有效降低人工檢測負擔，並提升檢測效率與判定一致性，進而確保產品品質之穩定性。

本研究之車充用穩壓 IC 於電路板組裝過程中，須經歷錫膏印刷、元件貼裝及迴流焊等製程步驟，每顆元件皆由八個焊點與電路板形成電性連接。然而，在實際生產過程中，易受到設備精度、錫膏用量或溫度曲線變化等因素影響，導致焊點產生少錫、偏移或黏著異常等瑕疵情形，進而影響產品品質與可靠度。傳統仰賴人工目視或抽樣方式進行檢測，不僅難以全面覆蓋所有元件，亦存在判斷主觀與檢測效率不足之問題，難以符合現代產線對品質控管之需求。

為提升車充用穩壓 IC 八腳焊點瑕疵檢測的效率與準確性，本研究提出一套基於深度學習的影像辨識方法，針對單腳焊點進行自動化品質判定，並進一步彙整為元件層級的整體瑕疵分析。透過焊點區域定位、影像資料集建構與模型訓練，本研究旨在建立可靠的焊點辨識機制，以評估所提出方法在實際產線應用中的可行性與效能表現。

1-2 研究背景

隨著電子製造產業朝向高精度與自動化發展，印刷電路板（PCB）與積體電路（IC）之品質檢測日益重要。PCB 作為電子產品的核心元件，其製程中的瑕疵將直接影響產品之功能與可靠度。Chen 等人[1]與 Zhang 等人[2]指出，傳統人工檢測方式雖可進行品質控管，但存在效率低落、易受人為因素影響及檢測成本較高等問題，因此自動光學檢測（Automated Optical Inspection, AOI）系統已逐漸成為產線上不可或缺之關鍵技術。

然而，傳統 AOI 系統多依賴影像比對與規則式演算法，在面對光照變化、元件位置偏移及複雜背景時，容易產生誤判與漏檢情形，仍需人工進行複檢，進而增加整體生產成本。Montoya Magaña 等人[3]針對 AOI 系統之限制進行分析，指出其在複雜瑕疵辨識上的不足，顯示傳統方法在精度與穩定性方面仍有改善空間。

為克服上述問題，近年來研究逐漸導入深度學習技術，以提升檢測系統之準確性與泛化能力。Ni 等人[4]與 Yan 等人[5]分別探討卷積神經網路（Convolutional Neural Network, CNN）於瑕疵檢測之應用，證實深度學習模型能自動擷取影像特徵，於複雜環境中相較傳統 AOI 方法具有更佳之辨識效果。此外，Xiao 等人[6]與 Sharma 等人[7]進一步指出，深度學習方法在工業檢測任務中能同時兼顧準確率與運算效率，逐漸成為主流技術。

在眾多深度學習方法中，YOLO（You Only Look Once）系列模型因具備高

效率與良好辨識能力，已廣泛應用於 PCB 與電子元件瑕疵檢測領域。Huang 等人[8]與 Li 等人[9]透過改良 YOLO 架構，提升模型對於微小瑕疵的辨識能力，有效改善傳統方法在小目標檢測上的不足。同時，Pham 等人[10]亦指出，透過模型優化與架構調整，可進一步提升檢測效率，使其更符合實際產線之即時應用需求。

此外，為進一步提升檢測效能，相關研究亦提出多種改良策略。Liu 等人[11]與 Xu 等人[12]針對模型架構與特徵提取方式進行優化，提升模型在複雜背景與多樣化瑕疵情境下之穩定性與準確率。然而，儘管上述研究在準確率與速度上已有顯著提升，實際應用於工業場域時，仍面臨瑕疵樣本不足與資料分布不平衡之問題，影響模型之泛化能力與可靠性。Fontana 等人[13]之研究亦指出，雖然深度學習技術已可應用於實際製造檢測流程，但在面對真實產線環境時，仍需進一步提升系統之穩定性與實用性。

綜合上述研究可知，現有方法雖已透過深度學習技術提升 PCB 與 IC 瑕疵檢測之效能，但在小樣本瑕疵辨識、資料不平衡處理以及實際產線應用等方面仍存在挑戰。因此，本研究針對 IC 焊點瑕疵檢測問題，提出一套結合 AOI 與深度學習之方法，並針對資料不平衡情形進行優化設計，以提升模型在實際應用環境中的準確性與穩定性。同時，本研究以 IC 層級判定作為最終評估標準，使檢測結果更貼近實際製造需求，進而提升系統之實用價值與產業應用潛力。

1-3 研究方法

本研究的方法包含焊點區域擷取、影像前處理、單腳瑕疵辨識與元件整體層級分析四個階段。

首先，在焊點區域擷取階段，本研究利用 ROI (Region of Interest) 定位方式，針對約 500 顆正常穩壓 IC 影像進行接腳區域標註，以建立接腳區域定位流程。完成定位流程建立後，將其套用於全部原始 IC 影像，自動擷取各接腳焊點區域並產生對應之單腳焊點影像，作為後續焊點瑕疵分類模型之輸入資料。此流程既確保焊點擷取的準確性，也大幅減少人工標註工作量，為後續影像處理、焊點瑕疵辨識與 IC 層級判定提供可靠基礎。

接著在影像前處理階段，我們針對每隻焊點的區域影像進行標準化處理，以提升影像品質並確保資料一致性。處理流程包括裁切、旋轉、縮放以及亮度與對比調整，以降低背景干擾與雜訊，讓焊點的細節特徵更加清晰可辨。同時，透過影像標準化與方向統一處理，提升焊點區域特徵之可辨識性，確保每張單腳影像都符合分類模型的輸入要求。這些前處理步驟不僅統一了影像品質，也為後續單腳瑕疵辨識模型提供了可靠、準確的訓練資料，進一步提升整體辨識系統的穩定性與效能。

在單腳焊點瑕疵辨識階段，本研究以影像前處理後之單腳焊點影像作為模型輸入，透過 YOLOv11 分類模型自動學習焊點外觀特徵，並進行焊點狀態分類與瑕疵辨識。為確保模型能穩定且準確地辨識各類瑕疵，我們統一了影像尺寸與像素規格，並將焊點影像與已知瑕疵標註進行比對，驗證資料的完整性與正確性。

透過多次模型測試與參數調整，我們確認了資料準備與特徵提取流程的穩定性，為單腳分類模型的訓練與效能評估建立可靠基礎。

最後在元件整體層級分析階段，我們將單腳瑕疵辨識模型的結果彙整至每顆元件，評估整顆車充用穩壓 IC 是否存在瑕疵。透過統計每顆元件八個焊點的辨識結果，我們量化不同瑕疵類型的分布情形，並以此進行元件層級的瑕疵判定。為確保分析結果的可靠性，我們將模型辨識結果與人工標註資料進行比對，驗證單腳辨識的準確性，並確認彙整後的元件判定結果與實際狀況一致。此整合分析不僅提供每顆元件的瑕疵狀態，也能呈現整批產品的良率與瑕疵分布特性，為生產品質監控提供重要依據。透過單腳辨識與元件層級整合，本研究建立了一套完整的自動化檢測流程，能有效支援車充用穩壓 IC 的品質評估與生產管理。

1-4 論文大綱

本論文共分為五個章節，完整說明本研究的背景、方法、實驗過程與結果，以及結論與應用價值。第一章為緒論，說明電子製造產業中產品品質檢測的重要性與挑戰，並提出以深度學習影像辨識技術進行焊點瑕疵檢測的解決方案。此外，本章亦說明研究目的及章節安排。第二章為文獻探討，回顧相關領域之研究進展，包括 IC 焊點檢測方法、ROI 技術在目標擷取中的應用、深度學習模型(如 YOLO)於瑕疵辨識的應用，以及影像前處理與元件層級品質評估的方法。本章並分析現有研究的成果與限制，提出本研究所面臨的技術挑戰。第三章為研究方法，描述本研究所採用的技術流程與實驗設計。本章分為四個部分，分別說明焊點區域定位與單腳焊點影像建構、影像前處理與資料集建構、單腳瑕疵辨識模型訓練及效能評估，以及元件整體層級瑕疵分析。透過這些方法，本研究建立了一套完整的自動化焊點瑕疵檢測流程，從單腳辨識到元件層級整合，實現全流程品質控制。第四章為實驗結果與分析，呈現各實驗步驟的數據結果與比較分析。本章依序討論焊點瑕疵分類模型於不同模型架構與訓練參數設定下之效能表現、影像前處理效果、單腳瑕疵辨識模型在不同參數與架構下的效能表現，以及元件整體層級分析結果。章中同時對比各種模型設定的表現差異，並分析瑕疵分布、辨識準確率與實際應用可行性，提供系統優勢、限制及潛在改進方向的完整討論。第五章為結論與應用價值，總結本研究成果，說明所建立的自動化檢測流程對車充用穩壓 IC 生產線品質管控與效率提升之實際作用。研究結果顯示，透過結合焊點區域定位、影像前處理、單腳瑕疵辨識與元件層級整合分析，可有效支援智慧化產線的品質檢測需求，並為後續智慧製造與生產流程優化提供技術參考。

第二章 穩壓 IC 焊點影像資料與瑕疵分析

本章旨在說明車充用穩壓 IC 焊點影像資料之建構流程與瑕疵分析方法，內容包含影像資料來源、焊點特性說明以及瑕疵分類定義。透過系統化的資料整理與標註流程，建立可供模型訓練與驗證之焊點影像資料集，並作為後續單腳瑕疵辨識與 IC 層級判定分析之基礎。

在實際電子組裝製程中，焊點品質直接影響元件電性穩定度與產品可靠性，因此建立具代表性的影像資料與明確的瑕疵定義標準，為發展自動化辨識方法之關鍵。本章將依序介紹穩壓 IC 焊點之應用背景、影像資料來源與整理方式，以及焊點瑕疵類型之定義與統計分析。

2-1 車充用穩壓 IC 焊點應用背景

車充用穩壓 IC 為車用充電模組中的核心電源管理元件，其主要功能為進行電壓轉換與輸出穩定控制，以確保充電過程具備安全性與穩定性。本研究探討之元件為八腳封裝形式之穩壓 IC，元件透過八個金屬接腳與電路板焊墊形成電性連接，完成電力傳輸與訊號控制功能。

由於八腳封裝之焊點尺寸微小且排列密集，各接腳焊點品質需同時符合導通與機械強度要求。若任一焊點出現少錫、焊點偏移、潤濕不良或接合不完全等瑕疵，可能導致導通不穩、接觸阻抗升高，甚至在長時間運作下產生過熱或失效風險，進而影響產品壽命與使用安全。

此外，焊點外觀差異往往細微且不易以肉眼穩定判定。傳統人工目視檢測方式容易受到檢測人員經驗、主觀判斷與疲勞因素影響，難以在高產量條件下維持一致性的品質判定標準。因此，透過影像化方式記錄焊點狀態，並建立可量化之瑕疵判定依據，成為提升檢測效率與品質穩定度的重要發展方向。

因此，在實際電子製造產線中，為提升檢測效率與判定一致性，通常導入自動光學檢測（AOI 機台）系統，透過影像擷取與演算法分析方式，對焊點外觀進行快速且大量之品質檢測。AOI 系統可於短時間內完成高解析度影像擷取，並針對焊點形貌、位置與亮度分布等特徵進行判斷，有效降低人工檢測所造成之主觀差異。

本研究之影像資料即取自實際電子製造產線之 AOI 檢測階段，其應用情境如圖 1、實際產線中 AOI 焊點檢測應用情境所示。該階段位於表面黏著製程（Surface Mount Technology, SMT）之後，主要負責對已完成焊接之 IC 元件進行外觀檢測，以確認各焊點之接合品質是否符合規範。透過此類檢測流程，可在產品進入後續組裝或出貨前即時篩除不良品，確保整體產品品質與可靠度。

因此，本研究後續所建立之焊點瑕疵辨識模型，亦以此實際 AOI 檢測情境為基礎進行設計與驗證，使研究成果能更貼近實務應用需求。




圖 1、實際產線中 AOI 焊點檢測應用情境

進一步觀察實際生產之產品型態，由於車充模組之電路板尺寸較小，於製造過程中通常採用多連板方式進行加工與檢測，以提升生產效率與製程穩定性。本研究使用之樣本亦採用 12 連板形式進行製作，其實際外觀如圖 2、車充穩壓 IC 應用電路板之多連板結構圖所示。

在此類多連板結構中，每一單元電路板皆包含一顆穩壓 IC 元件，而各單元於完成焊接後會一併進入 AOI 檢測流程進行外觀品質判定。由於單一電路板面積有限，IC 焊點於整體影像中所佔比例較小，且分布於不同子板位置，使得後續影像分析需具備有效之定位與區域擷取能力。

因此，本研究後續將針對連板影像中之 IC 區域進行擷取與處理，並以焊點為最小分析單位建立瑕疵辨識模型，以符合實際產線之檢測需求。




圖 2、車充穩壓 IC 應用電路板之多連板結構圖

為進一步說明單一電路板之結構配置，將多連板中之一單元電路板進行分離觀察，其結果如圖 3、單一電路板中穩壓 IC 元件位置示意圖所示。由圖中可見，每一單元電路板中配置有兩顆相同規格之八腳封裝穩壓 IC 元件，並分別分布於電路板之特定位置。

各 IC 元件皆透過八個金屬接腳與電路板焊墊形成焊接結構，其焊點分布具有固定幾何排列特性，且為本研究主要關注之檢測對象。由於單一電路板中同時存在多顆 IC 元件，且各 IC 於整體影像中所佔比例有限，因此在進行焊點品質判定時，需能準確定位 IC 所在區域，以利後續分析與判定。

基於上述結構特性，本研究將以 IC 元件為分析單位，進一步針對其焊點區域進行瑕疵辨識，以建立符合實際應用情境之檢測方法。



圖 3、單一電路板中穩壓 IC 元件位置示意圖

綜合上述可知，本研究所關注之穩壓 IC 焊點係存在於實際電子製造產線之多連板電路板中，並透過 AOI 檢測設備進行外觀品質判定。在此檢測流程中，系統會針對各 IC 元件擷取對應之影像資料，作為後續品質分析之依據。

因此，本研究後續所使用之影像資料，係建立於此實際產線檢測架構之上，並以 IC 焊點為核心分析對象。相關影像資料來源與內容說明，將於下一節中進一步介紹。

2-2 影像資料來源與說明

本研究之焊點影像資料取自實際表面黏著製程產線，涵蓋自錫膏印刷、元件貼裝至迴流焊接完成後之自動光學檢測（AOI 機台）階段影像。原始影像皆為包含完整穩壓 IC 之電路板區域畫面，可清楚觀察八個接腳焊點之錫料分布、位置偏移與接合狀態，作為後續瑕疵分析與辨識之基礎資料，其影像範例如圖 4、AOI 檢測取得之穩壓 IC 焊點影像範例所示。

本研究所使用之影像資料皆源自工廠實際生產流程，未對樣本進行人為修改或額外製作，僅進行資料標註與區域擷取處理。

每張原始影像解析度約為 363×572 像素，影像內容涵蓋整顆穩壓 IC 與其周邊焊接區域。為使模型能聚焦於關鍵檢測位置，本研究進一步針對各接腳焊點建立對應之檢測區域，僅擷取接腳末端實際與焊墊接合之焊接區段，而非整段金屬接腳本體。此作法可有效排除與焊點品質關聯性較低之背景資訊，使後續分析更具針對性。

經區域擷取後之單腳焊點影像尺寸約為 55×87 像素，影像範圍完整涵蓋焊料堆積形貌與接合輪廓特徵，在保留關鍵瑕疵資訊之同時，亦降低多餘背景對辨識結果之干擾。

透過此影像資料建構方式，可為後續單腳瑕疵分類與元件整體層級分析建立一致且可靠之資料基礎。上述接腳區域之擷取方式係透過接腳區域定位流程完成，其詳細流程與實作方法將於第三章中進一步說明。





圖 4、AOI 檢測取得之穩壓 IC 焊點影像範例

2-3 瑕疵類型定義

在完成焊點影像蒐集後，本研究依據焊點實際接合區域擷取各接腳之焊點影像，使模型輸入資料僅保留與焊接品質相關之區域。透過此方式可有效降低背景雜訊干擾，並提升各樣本於位置、尺度與觀測範圍上的一致性。完成區域擷取後，每一焊點影像皆視為獨立樣本，作為後續模型訓練與測試之基礎資料。

本研究依據焊點外觀特徵與實務檢測判定準則，將焊點狀態區分為五種主要焊接狀態與一類其他異常，共六種類型。相關分類結果與代表性影像整理如表 1、焊點狀態分類與對應影像及特徵說明所示。

表 1、焊點狀態分類與對應影像及特徵說明

焊點類型	正常	偏移	少錫	假焊	多錫
影像					

本研究依據焊點外觀特徵與實務檢測判定準則，將焊點狀態區分為六種類型，分別說明如下：

(1) 正常焊點：

焊料覆蓋完整，潤濕良好，焊點外形均勻且與焊墊中心對齊，無明顯裂縫、偏移或覆蓋不足情形，屬於符合製程品質要求之焊接狀態。

(2) 焊點偏移：

焊點中心位置相對於焊墊中心產生位移，當偏移量超過焊墊寬度三分之一時，即判定為偏移瑕疵。此情形多由貼裝位置誤差或迴流時元件滑動所導致，可能影響電性接觸可靠度。

(3) 少錫：

焊料覆蓋面積不足，當焊料覆蓋率低於焊墊面積之 75% 時，即定義為少錫瑕疵。此類缺陷通常源自錫膏印刷量不足或潤濕性不佳，易造成接合強度不足或導通不穩定。

(4) 冷焊：

焊點表面出現裂紋、粗糙顆粒感或異常變色現象，顯示焊料未完全熔融或潤濕不良。假焊多與迴流溫度曲線不當或受污染有關，將顯著降低焊接可靠度。本研究之假焊判定係依據 AOI 檢測人員之實務判讀標準與產線不良判定結果進行標註。

(5) 多錫：

焊料堆積量明顯過多，超出正常焊點應有之外形輪廓，產生過度隆起或外溢現象。實務判定上，多錫通常依焊料覆蓋高度、外擴面積或是否逼近相鄰焊墊作為判斷依據。當焊料堆積已超出焊墊設計範圍，或形成不對稱團塊狀堆積，即歸類為多錫瑕疵。此類缺陷可能提高短路風險，並影響後續可靠度。

除上述可明確定義之焊點瑕疵類型外，實務資料中仍存在部分無法歸入既有分類之非典型異常樣態，為完整涵蓋實際 AOI 檢測過程中可能出現之情形，另將其整理如表 2、非典型焊點異常類型與影像說明所示。

表 2、非典型焊點異常類型與影像說明

其他異常	裁切不完整	遭異物遮蔽	影像模糊	焊點燒焦
影像				

(6) 其他異常：

除上述可明確歸類之焊接瑕疵外，實務篩選過程中亦存在部分非典型或不可預期之異常樣態，故另行歸類為其他類型。其情形包含但不限於：

- 影像取像異常（裁切不完整或拍攝偏移）
- 焊點區域遭異物或元件遮蔽
- 影像品質異常（模糊、失焦或曝光不良）
- 焊點燒焦、碳化或異常變色

此類異常多屬製程設備失誤、取像問題或突發製造狀況所致，雖不屬典型焊接品質缺陷，然其對後續檢測判讀與產品可靠度仍具潛在影響，因此於本研究中獨立建構為一類進行分析。

為確保模型訓練與效能評估之獨立性，本研究以 IC 為單位進行資料切分，並將樣本劃分為訓練集、驗證集與測試集。模型僅於訓練集與驗證集資料上進行學習與參數調整，測試集則完全保留為獨立資料，用於最終模型效能評估，以確保評估結果之客觀性與泛化能力。

2-4 焊點影像資料集建構方法

在完成焊點影像蒐集與瑕疵類型定義後，本研究依據前述標註準則建立焊點瑕疵影像資料集，作為後續深度學習模型訓練與效能評估之基礎。所有影像資料皆來源於實際表面黏著製程產線之自動光學檢測設備，原始影像包含完整穩壓 IC 及其八個焊點區域，本研究共蒐集 8,843 顆 IC 原始影像。由於實際產線中瑕疵樣本數量相對有限，因此除原始 AOI 檢測資料外，亦蒐集相同產品型號之瑕疵焊點影像作為補充資料來源，以增加各類瑕疵樣本之代表性，建立後續模型訓練與評估所需之資料集。

為建立適用於單腳焊點辨識之資料格式，本研究先透過接腳區域定位流程擷取各接腳焊點區域，再將原始 IC 影像轉換為焊點層級資料，使每一接腳焊點可作為獨立樣本進行分析。相關資料建構流程如圖 5、焊點影像資料集建構流程示意圖所示。




圖 5、焊點影像資料集建構流程示意圖

該流程涵蓋從原始 AOI 影像至最終焊點資料集之完整轉換過程，以確保資料一致性與後續模型訓練之有效性。

理論上每顆 IC 可對應 8 個焊點樣本，惟於實際資料建構過程中，部分影像因區域擷取邊界不足、焊點遮蔽、影像模糊或清晰度不佳等因素，導致少數焊點

樣本無法保留。因此，經接腳區域擷取後共取得 70,613 個焊點樣本，再經影像完整性與品質檢查後，最終保留 70,572 個有效焊點影像樣本。所有樣本均依據第 2-3 節所建立之瑕疵分類標準完成標註，形成包含正常與各類焊點瑕疵之影像資料庫。

為說明焊點影像資料之結構，本研究將單一 IC 之八個接腳影像以示意方式排列，如圖 6、單一 IC 八個接腳焊點示意圖所示，各焊點依封裝位置區分為 Pin1 至 Pin8，以利後續單腳焊點分類與 IC 層級結果整合分析。




圖 6、單一 IC 八個接腳焊點示意圖

為提升資料一致性，本研究於資料集建構過程中，將焊點影像整理為統一之基準方向，使各樣本於排列方式與觀測方向上具一致性，其具體處理方式將於第三章說明。

在資料分割策略方面，考量產線實際瑕疵比例極低之特性，以及避免訓練與測試資料間產生資訊重疊，本研究以 IC 為單位進行區段式切分，確保不同階段資料來源彼此獨立。編號第 1 至第 6,000 顆 IC 作為模型開發資料池，並自其中抽樣建立訓練集與驗證集；編號第 6,001 至第 8,843 顆 IC 則作為獨立測試資料池，並自其中抽樣建立測試集，用於後續單腳層級辨識效能評估與 IC 層級驗證分析。各資料集實際使用數量如表 3 所示。

透過上述資料建構與切分流程，本研究建立一套具代表性、來源獨立且可支援深度學習訓練之焊點影像資料集，作為後續基於 YOLOv11 之焊點瑕疵分類模型訓練、IC 層級推論分析，以及模型泛化能力驗證之基礎。由於實際產線中正常焊點比例遠高於瑕疵焊點，因此本研究資料集呈現類別不平衡特性。為避免模型評估受到類別分布影響，後續除整體準確率（Overall Accuracy）外，亦搭配 Defect Recall、Macro F1-score 及 Balanced Accuracy 等指標進行綜合評估，以更完整反映模型對各類瑕疵之辨識能力。

第三章 基於 YOLOv11 的穩壓 IC 焊點瑕疵辨識方法

在完成焊點影像資料建構與瑕疵類型定義後，本研究進一步導入深度學習技術，建立焊點瑕疵自動辨識方法。透過設計適當之模型架構與完整訓練流程，使系統能自動由焊點影像學習不同瑕疵特徵，並完成單腳焊點之分類判定。

本章主要說明本研究所提出之焊點瑕疵辨識方法與系統架構，內容包含焊點影像資料建構與前處理、YOLOv11 分類模型設計、訓練參數設定，以及模型效能評估方式。本研究整體辨識流程如圖 7、單腳焊點至 IC 層級之 YOLOv11 瑕疵辨識整合流程所示。




圖 7、單腳焊點至 IC 層級之 YOLOv11 瑕疵辨識整合流程圖

系統首先以單腳焊點影像作為輸入，透過 YOLOv11 分類模型進行焊點狀態判定，再整合單一 IC 之八個焊點結果，完成 IC 層級良品 (OK) 與不良品 (NG) 之最終判定。各階段方法與實作細節將於本章後續各節中進一步說明。

3-1 系統流程與整體架構

本研究之核心目標為建立穩壓 IC 焊點瑕疵分類模型。為建立可供模型訓練之單腳焊點資料集，首先利用接腳區域定位方式自原始 IC 影像中擷取各接腳焊點區域，完成單腳焊點影像建構；其後再以焊點影像作為輸入，建立基於 YOLOv11 之焊點瑕疵分類模型，進行各類焊點缺陷辨識與 IC 層級品質判定。

為建立單腳焊點影像資料集，本研究先進行接腳區域定位與焊點影像裁切。由於原始影像係以整顆穩壓 IC 為拍攝單位，因此需先取得各接腳焊點區域位置，再將其轉換為單腳焊點影像，以作為後續分類模型之輸入資料。

3-2 焊點影像生成與前處理

為建立可供焊點瑕疵辨識模型訓練之資料集，本研究針對原始穩壓 IC 影像進行接腳區域擷取、單腳焊點樣本建構與影像前處理作業。由於原始影像係以整顆 IC 為單位，無法直接作為單腳焊點分類模型之輸入，因此須先透過接腳區域定位流程自動擷取各焊點區域，再完成資料整理與品質篩選流程。

本節將依序說明接腳區域定位流程、單腳焊點資料集建構流程，以及影像前處理與品質檢查方法。

3-2-1 接腳區域定位與焊點影像生成

由於原始 AOI 影像係以整顆穩壓 IC 為拍攝單位，影像中同時包含元件本體、八個接腳焊點及周邊電路板背景資訊，若直接作為分類模型輸入，將降低模型對單一焊點特徵之學習效果。因此，本研究先建立接腳區域定位流程，將原始 IC 影像轉換為單腳焊點影像，以作為後續瑕疵分類模型之輸入資料。

在接腳 ROI 定位階段，本研究選取 500 顆正常穩壓 IC 影像進行人工標註。由於每顆 IC 具有 8 個接腳，共完成 4,000 個接腳區域標註 (bounding box)，作為建立接腳區域定位與自動化裁切流程之基礎資料。標註範圍以各接腳末端與焊墊接合之焊點區域為主，作為建立接腳區域定位流程之基礎資料。

完成接腳區域定位流程建立後，將其套用於全部原始 IC 影像，自動擷取八個接腳焊點區域，並依定位結果進行區域裁切，產生對應之單腳焊點影像，作為後續焊點瑕疵分類模型之輸入資料。

透過自動化 ROI 定位與裁切流程，可有效降低人工逐張裁切焊點影像所需之時間成本。本研究共蒐集 8,843 顆穩壓 IC 影像，其中包含正常與瑕疵樣本，經接腳區域定位與焊點裁切後，可產生超過 70,000 個焊點樣本，若完全採用人工方式進行單腳焊點裁切，將耗費大量時間與人力。因此，本研究利用接腳區域定位方式自動產生單腳焊點影像，不僅提升資料建構效率，亦可維持焊點影像於位置、尺度與範圍上的一致性，降低人工操作所造成之資料偏差，作為後續焊點瑕疵分類模型建立之基礎。完成上述流程後，其接腳 ROI 定位與單腳焊點影像生成之整體架構如圖 8 所示。



圖 8、基於接腳 ROI 之單腳焊點影像生成流程示意圖

接腳 ROI 定位與焊點裁切結果如圖 8、基於接腳 ROI 之單腳焊點影像生成流程示意圖所示，可呈現由原始 IC 影像轉換為單腳焊點資料之完整流程。

3-2-2 接腳裁切與焊點影像生成

在完成接腳區域定位後，本研究依據接腳區域定位結果，進行單腳焊點影像之裁切與生成。該步驟之主要目的在於將 IC 層級之影像資料轉換為標準化之單腳焊點影像，以作為後續瑕疵分類模型之輸入。

具體而言，接腳區域定位流程可取得每顆 IC 中八個接腳之邊界框位置，本研究依據各 ROI 框座標資訊，自原始 IC 影像中裁切對應區域，取得各接腳之焊點影像。裁切範圍以焊點實際接合區域為中心，並保留周圍適當背景資訊，以確保焊點形貌特徵完整呈現。

為維持不同樣本間之一致性，所有裁切後之單腳焊點影像皆統一轉換為固定尺寸格式，使其符合後續分類模型之輸入需求。同時，針對裁切過程中可能產生之邊界偏移問題，本研究透過固定比例擴張 ROI 範圍，以避免焊點關鍵區域遺失。

經上述處理後，每顆 IC 影像理論上可生成八張單腳焊點影像，分別對應不同接腳位置。惟部分樣本因影像模糊、焊點遮蔽、裁切不完整或影像品質不佳等因素而予以排除，因此最終保留 70,572 張有效焊點影像作為後續焊點瑕疵分類模型之輸入資料。

3-2-3 影像標準化與方向統一

為確保後續焊點瑕疵分類模型之輸入資料具備一致性，本研究於資料建構階段進行影像標準化與方向統一處理，以降低因影像尺寸與方向差異所造成之特徵偏移問題。

在影像標準化部分，所有單腳焊點影像皆統一調整為固定解析度，使模型輸入維度保持一致，以避免因尺寸不一致而影響特徵提取與模型收斂穩定性。透過統一輸入尺寸，可確保後續訓練過程中各類焊點樣本具有相同的特徵表示基準。

在方向統一部分，考量實際 AOI 拍攝過程中可能存在元件擺放方向差異或影像翻轉情形，本研究針對焊點影像進行方向校正處理，使所有焊點均以一致之基準方向呈現。此步驟可有效降低模型因方向變異所產生之誤判風險，提升瑕疵特徵學習之穩定性。

經上述處理後，所有焊點影像均轉換為尺寸與方向一致之標準化資料格式，作為後續基於 YOLOv11 之焊點瑕疵分類模型輸入資料。

3-2-4 訓練/驗證/測試資料切分策略

本研究資料集共包含 8,843 顆穩壓 IC 影像，其中包含正常樣本與工廠提供之瑕疵樣本。所有資料均經接腳區域定位與焊點裁切後建立焊點資料集，再依 IC 為單位進行訓練集、驗證集與測試集之切分，以避免同一顆 IC 之焊點同時出現在不同資料集合中。為避免同一顆 IC 所產生之八個焊點影像分散於不同資料集合，造成訓練與測試資料間產生高度相似樣本而影響評估客觀性，本研究採用以 IC 為單位之資料切分方式，而非以單腳焊點影像隨機分配。在此策略下，同一顆 IC 所對應之八個焊點影像僅會出現在單一資料集合中，以確保測試資料皆為未參與訓練之獨立元件資料。

本研究將資料劃分為訓練集、驗證集與測試集，其中訓練集用於模型參數學習，驗證集用於模型訓練過程之性能監控與最佳模型選擇，測試集則完全獨立於訓練流程之外，用於最終模型效能評估。

由於本研究需進行不同模型版本與訓練參數之比較實驗，因此於模型開發階段，將自前 6,000 顆 IC 資料中依實驗需求建立訓練集與驗證集。表 3 所列之資料數量為本研究模型訓練與比較實驗實際使用之資料量，而非模型開發資料池之總量。編號第 6,001 至第 8,843 顆 IC 則保留作為獨立測試資料來源，以確保最終評估結果之客觀性與泛化能力。

表 3、本研究訓練、驗證與測試資料分配統計

資料集	IC 數量	焊點樣本數	用途
Training	400	3200	訓練
Validation	100	800	驗證
Test	2500	20000	最終評估

本研究進一步檢視訓練資料之類別分布情形，可發現正常焊點樣本數明顯高於各瑕疵類別，呈現類別不平衡之分布特性。由於本研究採用 IC 為單位進行資料切分，各資料集合之類別分布係由原始資料標註結果所決定。

此外，本研究所有統計結果皆以單腳焊點影像（pin-level samples）為計算單位，各類別樣本數代表焊點數量而非 IC 顆數。由於單一 IC 可能同時包含多個焊點瑕疵，因此各類別樣本數與 IC 數量之間不具固定對應關係。

本研究之分析係基於既有資料分布條件下進行，旨在評估模型於該資料條件下之辨識能力。

3-3 焊點瑕疵分類模型設計

完成焊點影像資料建構、前處理與資料切分後，本研究進一步建立焊點瑕疵分類模型，以自動判定單腳焊點之品質狀態與瑕疵類別。由於焊點瑕疵多屬細微之外觀差異，例如錫量異常、接合形貌不完整、位置偏移或表面輪廓變化，模型除需具備良好分類能力外，亦須能有效擷取局部特徵，以提升辨識準確性。

基於上述需求，本研究採用 YOLOv11 作為焊點瑕疵辨識之核心模型架構，並以分類任務模式進行訓練，使模型直接針對輸入之單腳焊點影像輸出對應類別結果。相較於傳統人工檢測方式，透過深度學習模型可自動學習不同瑕疵類型之影像特徵，提升檢測效率與判定一致性。

此外，考量實際產線應用需求，模型除需具備辨識準確度外，亦須兼顧推論速度與部署可行性。因此，本研究針對不同模型版本與訓練參數進行比較分析，據以選擇最適合本研究資料特性之模型設定。

本節將依序說明 YOLOv11 模型架構選用理由，以及本研究焊點瑕疵分類任務之類別定義與模型輸出設計。

3-3-1 模型架構選用

本研究焊點瑕疵辨識任務之輸入資料為單腳焊點影像，影像尺寸較小，且瑕疵特徵主要集中於焊料外觀形貌、邊緣輪廓與接合區域細節，因此模型需具備良好之局部特徵擷取能力，同時兼顧運算效率與推論速度，以符合後續自動化檢測之應用需求。

綜合考量模型辨識效能、訓練效率與部署彈性，本研究選用 YOLOv11 作為基礎深度學習架構。YOLO 系列模型最初主要應用於物件偵測任務，具備端到端訓練與高推論效率之特性，已廣泛應用於即時影像辨識與工業視覺檢測領域。近年 YOLO 架構亦提供 Classification 模式，可直接應用於影像分類任務。本研究採用 YOLOv11 Classification 模型作為焊點瑕疵辨識架構，以單腳焊點影像作為輸入，輸出對應之焊點類別結果。

相較於傳統卷積神經網路需自行設計特徵提取與分類流程，YOLOv11 提供完整之訓練框架與多尺度模型配置（n、s、m、l 等版本），可直接應用於本研究之焊點瑕疵辨識任務，並提升實驗設計之一致性與可比較性。

考量本研究未來應用情境為 AOI 自動化檢測系統，因此除分類準確率外，模型推論速度與部署便利性亦為重要考量因素。YOLOv11 提供不同規模模型版本，可於相同架構下進行效能比較，因此本研究選用 YOLOv11 作為焊點瑕疵分類模型，並進一步比較不同模型規模之辨識效能，以作為最終模型選擇之依據。

3-3-2 焊點分類任務定義

本研究之焊點瑕疵辨識任務係針對單腳焊點影像進行多類別分類，其輸入為經接腳區域擷取後之單一焊點影像，輸出為對應之焊點品質判定結果，用以描述該焊點是否存在瑕疵及其所屬類別。

本研究將焊點分類問題定義為多類別監督式學習任務，各類別依據第二章所建立之瑕疵定義進行標註，包含正常焊點與不同型態之焊點缺陷類別。模型輸出為各類別之機率分布，並以最大機率對應之類別作為該焊點之預測結果。

由於本研究後續需進行 IC 層級之品質判定，因此單腳焊點分類結果將作為 IC 層級整合判定之基礎輸入，透過對同一 IC 內八個焊點分類結果進行整合，以形成元件層級之判定依據。

因此，本研究之焊點分類任務主要聚焦於單腳焊點層級之辨識，並提供後續 IC 層級判定所需之基礎輸入資訊。




圖 9、焊點分類任務示意圖

3-4 模型訓練策略與參數設計

本研究為建立適用於焊點瑕疵分類任務之最佳模型架構，採兩階段實驗設計進行模型訓練策略規劃與參數調整。第一階段針對不同 YOLOv11 模型規模進行初步篩選，以確定具備基本辨識能力之模型；第二階段則針對篩選後之模型進行訓練參數調整與效能比較，以進一步提升模型表現。

模型訓練採用監督式學習方式，並以已標註之單腳焊點影像作為輸入資料。本章主要說明模型版本比較設計、訓練參數設定與調整策略、學習率實驗設計，以及最終模型選擇準則，以建立完整之模型訓練流程與決策依據。

3-4-1 模型版本比較設計

本研究為建立適用於焊點瑕疵分類任務之最佳模型，採取兩階段模型篩選策略進行比較分析。

在第一階段比較中，YOLOv11n、YOLOv11s 與 YOLOv11m 皆於相同資料集與訓練條件下進行訓練，以評估不同模型規模於焊點瑕疵分類任務中之基礎辨識能力。根據初步實驗結果，YOLOv11n 之整體分類效能明顯低於 YOLOv11s 與 YOLOv11m，因此於後續實驗中予以排除。

在第二階段中，則針對 YOLOv11s 與 YOLOv11m 進行進一步比較分析，並搭配不同訓練參數設定進行實驗，以作為最終模型選擇之依據。為清楚呈現本研究之模型篩選流程與各階段比較策略，其整體設計架構如圖 10、YOLOv11 模型版本兩階段篩選流程示意圖所示。




圖 10、YOLOv11 模型版本兩階段篩選流程示意圖

由圖 10、YOLOv11 模型版本兩階段篩選流程示意可知，本研究首先以 YOLOv11n、YOLOv11s 與 YOLOv11m 進行第一階段基礎比較，並排除效能較差之 n 模型；再以 s 與 m 模型為候選模型，進一步透過不同訓練參數組合進行第二階段精細比較，以篩選出最終最佳模型。由於不同模型規模在參數量、運算資源需求與辨識能力上存在差異，因此透過兩階段比較方式，可更有效評估各模型於焊點瑕疵辨識任務中的適用性。

3-4-2 訓練參數組合設計

本研究為提升焊點瑕疵分類模型之辨識效能與穩定性，針對訓練參數進行系統性控制變因之組合比較分析，以探討不同參數設定對模型收斂速度與分類效能之影響。

考量深度學習模型之訓練效率與硬體資源限制，本研究選擇批次大小 (Batch Size)、影像輸入尺寸 (Image Size) 與訓練輪數 (Epoch) 作為主要比較參數，並於其他條件固定之情況下進行比較分析。此外，本研究另針對學習率 (Learning Rate) 進行獨立實驗，以探討其對模型收斂速度與分類效能之影響。

此外，本研究將三種 YOLOv11 模型 (YOLOv11n、YOLOv11s 與 YOLOv11m) 與不同參數組合進行交叉實驗設計，使每一種模型皆分別搭配所有參數設定進行訓練與評估，以形成完整之對照實驗架構，共計 12 組實驗設定，用以分析模型規模與訓練參數間之交互影響。各模型與參數組合之完整實驗設定整理如表 4 所

示。

表 4、訓練參數組合設計與實驗設定

Model	Batch	Image Size	Epoch	說明
S-1	16	320	80	基準組
S-2	32	320	80	batch 影響
S-3	16	640	80	影像大小影響
S-4	32	640	80	高負載組

上述四組訓練參數配置將分別套用於 YOLOv11n、YOLOv11s 與 YOLOv11m 三種模型架構，因此共形成 12 組模型訓練實驗，用以分析模型規模與訓練參數對焊點瑕疵辨識效能之影響。學習率參數則於完成模型版本與訓練參數篩選後，再進行獨立比較分析，其設定方式將於 3-4-3 節說明。

由表 4、訓練參數組合設計與實驗設定可知，本研究採用模型規模與訓練參數之交叉組合設計，使 YOLOv11n、YOLOv11s 與 YOLOv11m 皆分別於四種不同參數設定下進行訓練與評估，以形成完整之 12 組實驗比較架構。

透過此設計，可同時分析模型規模與訓練參數對焊點瑕疵分類效能之影響，並進一步觀察不同模型在相同參數條件下之表現差異，以作為後續最佳模型與參數組合選擇之依據。

3-4-3 學習率調整策略設計

本研究為提升焊點瑕疵分類模型之收斂穩定性，針對學習率（learning rate）進行系統性比較分析。學習率為影響模型權重更新幅度之重要超參數，若設定過大可能導致訓練震盪甚至影響收斂穩定性，設定過小則可能降低收斂速度並增加訓練時間，因此需透過實驗方式進行適當範圍之選擇。

在學習率設定方面，本研究選取 0.001、0.0009、0.0008 與 0.0007 四種學習率進行訓練比較，並於相同模型架構與資料切分條件下進行實驗，以確保比較過程之公平性與一致性。各模型訓練結果將於第四章中以 Defect Recall、Macro F1、Balanced Accuracy 與 Overall Accuracy 等指標進行分析。上述學習率設定係參考 YOLO 系列模型常用之訓練參數範圍進行規劃，並配合本研究資料集特性進行比較分析。

3-4-4 最終模型選擇準則

本研究為選定最終之焊點瑕疵分類模型，建立一致之模型選擇決策規則，以作為後續模型比較結果之判定依據。

在模型選擇策略上，首先以不同模型規模（YOLOv11n、YOLOv11s、YOLOv11m）之整體表現進行初步篩選，排除辨識效能明顯不足之模型；其次針對候選模型進一步比較不同訓練參數組合之穩定性表現，以確保模型具備良好之收斂能力與泛化能力。

此外，考量實際工業自動光學檢測（AOI）應用情境，本研究在模型選擇上

除整體準確率（Overall Accuracy）外，亦特別重視瑕疵樣本之漏檢問題。基於產線品質控管需求，工廠自動光學檢測系統通常採取「寧可誤判正常為瑕疵，亦不可漏檢真正瑕疵」之原則，因此本研究將 Defect Recall 作為主要評估指標，並搭配 Macro F1-score 與 Balanced Accuracy 進行綜合分析，以兼顧模型對各類別之辨識能力與整體分類表現。

最終模型之選擇將綜合考量 Defect Recall、Macro F1-score、Balanced Accuracy 與 Overall Accuracy 等評估指標之表現，並參考模型訓練穩定性與參數規模，選擇於各項指標間具有較佳整體表現之模型，作為後續 IC 層級焊點整合判定與系統應用之基礎。

3-5 模型效能評估方法

本研究為客觀評估焊點瑕疵分類模型之辨識效能，建立一致且標準化之模型評估方法，以作為不同模型與參數組合間之比較依據。透過標準化評估指標與分析方法，可確保各模型之比較結果具備公平性與一致性。

本研究主要針對焊點瑕疵分類任務，採用 Overall Accuracy、Defect Recall、Macro F1-score 與 Balanced Accuracy 作為主要評估指標，並輔以 Precision 與混淆矩陣（Confusion Matrix）進行分析。其中 Overall Accuracy 用於評估模型整體分類正確率；Defect Recall 用於衡量模型對瑕疵樣本之檢出能力；Macro F1-score 用於綜合評估各類別之 Precision 與 Recall 表現；Balanced Accuracy 則用於降低類別不平衡對評估結果之影響，以反映模型於各類別間之整體辨識能力。

由於本研究資料具有類別不平衡特性，單一 Accuracy 指標可能無法完整反映模型於少數瑕疵類別之辨識能力，因此本研究特別重視 Defect Recall、Macro F1-score 與 Balanced Accuracy 等指標，以確保模型具備足夠之瑕疵檢出能力與分類穩定性。

此外，本研究透過混淆矩陣進一步分析模型分類結果，以觀察各類別之預測正確與錯誤分布情形，並辨識不同瑕疵類別間之誤判關係。此方法除可補足單一數值指標之不足外，亦有助於後續錯誤分析與模型優化。

3-5-1 分類評估指標

本研究採用 Accuracy、Precision、Recall 與 F1-score 作為焊點瑕疵分類模型之基礎評估指標，以衡量模型於不同面向之分類效能。

其中，Accuracy 用於評估模型整體分類之正確率，可反映模型整體預測結果之準確程度；Precision 用於衡量模型預測為特定類別樣本時之正確比例，以反映模型預測結果之可靠性；Recall 用於衡量實際樣本中被正確辨識之比例，以評估模型之檢出能力；F1-score 則為 Precision 與 Recall 之調和平均，用以衡量模型於精確率與召回率之間之平衡性。

由於本研究之焊點瑕疵資料於各類別分布上存在不均衡現象，若僅以 Accuracy 作為單一評估指標，可能無法完整反映模型於各瑕疵類別之實際辨識

表現。因此，本研究於模型比較與最終模型選擇時，除上述基礎評估指標外，亦進一步採用 Defect Recall、Macro F1-score、Balanced Accuracy 與 Overall Accuracy 等指標進行綜合分析，以降低類別分布差異對評估結果之影響，並更完整反映模型於各類瑕疵之辨識能力。Accuracy、Precision、Recall 及 F1-score 之計算係依據混淆矩陣（Confusion Matrix）統計結果進行。其中 Accuracy 代表整體分類正確率；Precision 代表模型預測為某類別時之正確比例；Recall 代表實際樣本被正確辨識之比例；F1-score 則為 Precision 與 Recall 之綜合指標。

此外，考量本研究資料具有類別不平衡特性，因此另採用 Defect Recall、Macro F1-score 與 Balanced Accuracy 作為主要評估指標。其中 Defect Recall 用於評估模型對瑕疵樣本之檢出能力；Macro F1-score 為各類別 F1-score 之平均值；Balanced Accuracy 則為各類別 Recall 之平均值，以降低類別不平衡對評估結果之影響。

3-5-2 混淆矩陣分析方法

本研究使用混淆矩陣（Confusion Matrix）作為模型分類結果之分析工具，以觀察模型於焊點瑕疵分類任務中之預測分布情形。混淆矩陣透過實際標籤與預測結果之交叉統計，可呈現各類別之正確分類與錯誤分類狀況，並作為模型性能分析之依據。

本研究於焊點層級（Pin-level）建立混淆矩陣，以分析各瑕疵類別間之分類表現，進一步觀察模型對不同特徵之辨識能力。

IC 層級結果則係由單一 IC 內 8 個焊點之 Pin-level 分類結果，依據既定整合判定規則（任一焊點判定為瑕疵即該 IC 判定為 NG）進行推論後所得到之結果，用以反映模型於元件層級之實際應用行為，並於後續整體效能評估中進行統計分析。

3-5-3 IC 層級判定規則（8 腳整合）

本研究除針對單一焊點進行分類外，亦建立 IC 層級判定機制，以符合實際自動光學檢測（AOI）之應用需求。

在 IC 層級判定中，每顆穩壓 IC 包含 8 個焊點，系統依據 8 個焊點之分類結果進行整合判定。其判定規則如下：若任一焊點被判定為瑕疵類別，則該 IC 判定為不良品（NG）；僅當 8 個焊點皆判定為正常（OK）時，該 IC 始判定為良品（OK）。此 IC 層級整合判定規則本質上屬於基於缺陷觸發之邏輯判定（fault-trigger rule），用以模擬產線中單點失效即整體失效之品質控制原則。

為清楚說明 IC 層級之整合判定流程，本研究將上述判定規則整理如圖 11 所示。




圖 11、IC 層級焊點整合判定流程示意圖

由圖 11 可知，IC 層級判定係以 8 個焊點之分類結果為基礎進行邏輯整合判斷。當所有焊點皆判定為正常類別時，該 IC 輸出為 OK；若任一焊點被判定為瑕疵類別，則整體 IC 即判定為 NG。

IC 層級評估係基於 pin-level 分類結果進行系統層級推論，用以反映元件層級之品質判定行為。

此判定方式係參考 AOI 實際品質管制流程設計，只要任一焊點存在瑕疵，即可能影響元件焊接品質與可靠度，因此採用單點失效即判定 NG 之保守判定原則，以符合實際產線之品質管理需求。

第四章 實驗結果與分析

本章主要針對本研究所建立之焊點瑕疵分類模型進行實驗結果與效能分析，並依據前章所設計之模型架構、訓練策略與評估方法，呈現各項實驗結果之比較與分析。

本研究首先針對不同模型規模（YOLOv11n、YOLOv11s、YOLOv11m）與不同訓練參數組合進行比較，並以分類評估指標（Accuracy、Precision、Recall、F1-score）進行量化分析，其中以 Defect Recall 作為主要評估指標，以探討不同設定對模型辨識效能之影響。

接著，針對最佳模型進一步於焊點層級（Pin-level）與 IC 層級（IC-level）進行效能評估，其中 IC 層級結果係由 pin-level 分類結果依據 IC 層級整合判定規則推論所得，用以分析模型於元件層級之實際判定能力。

最後，透過混淆矩陣進一步檢視各類別之分類正確性與誤判分布情形，並綜合各項實驗結果進行整體比較分析，以作為最終模型選擇與實際應用之依據。

4-1 模型參數實驗結果分析

本節針對本研究所設計之模型訓練實驗結果進行整體分析與比較，包含不同模型規模（YOLOv11n、YOLOv11s、YOLOv11m）與不同訓練參數組合之效能表現。

實驗結果以焊點分類任務之各項評估指標（Defect Recall、Macro F1-score、Balanced Accuracy 及 Overall Accuracy）進行量化比較，以分析不同模型與參數設定對瑕疵辨識效能之影響，其中以 Defect Recall 作為主要觀察指標，用以反映模型對瑕疵樣本之檢出能力，並符合實際自動光學檢測（AOI）對降低漏檢之核心需求。

本節首先說明不同模型規模之初步比較結果，以篩選具備較佳基礎辨識能力之模型；接著針對候選模型進一步分析不同訓練參數組合之表現差異；最後彙整各組實驗結果，作為後續最佳模型選擇與參數優化之依據。

4-1-1 模型比較之結果

本節針對不同 YOLOv11 模型規模（YOLOv11n、YOLOv11s 與 YOLOv11m）於焊點瑕疵分類任務之實驗結果進行比較分析，以評估模型規模對辨識效能之影響，並作為後續參數選擇之依據。

為確保實驗比較之公平性與一致性，所有模型皆採用相同之資料集切分方式與訓練設定進行訓練，並固定學習率為 0.001，以排除超參數差異對模型比較結果之影響，使不同模型之效能差異主要反映於模型結構本身之特性。評估指標包含 Defect Recall、Macro F1-score、Balanced Accuracy 與 Overall Accuracy，用以綜合衡量模型於瑕疵辨識能力與整體分類穩定性之表現。

根據初步實驗結果顯示，YOLOv11n 於各項評估指標之表現明顯低於

YOLOv11s 與 YOLOv11m，尤其在瑕疵類別之辨識能力方面呈現較為明顯之落差，顯示其於本研究資料條件下對細部特徵之學習能力仍相對有限。因此，YOLOv11n 雖具備較低運算成本之優勢，但於 Defect Recall 與 Macro F1-score 等指標上明顯低於 YOLOv11s 與 YOLOv11m，顯示其無法滿足本研究對瑕疵檢測準確性之需求，故後續實驗不再將其列為主要候選模型。

相較之下，YOLOv11s 與 YOLOv11m 於各項評估指標上皆展現較佳之整體表現，兩者在 Defect Recall 與 Macro F1-score 等與瑕疵辨識能力高度相關之指標上均維持穩定水準，顯示其對焊點特徵具有較佳之學習能力與分類能力。進一步比較可知，YOLOv11s 與 YOLOv11m 之整體表現差異相對有限，顯示兩種模型於本研究資料條件下皆具備作為候選模型之潛力。

整體而言，YOLOv11n 雖具有較高之運算效率，但在瑕疵辨識能力與整體分類穩定性方面表現不足；相對而言，YOLOv11s 與 YOLOv11m 則展現較佳之平衡性與實務應用潛力。各模型之量化結果如表 5 所示。

表 5、不同 YOLOv11 模型規模之分類效能比較

Model	Defect Recall	Macro F1	Balanced Acc	Overall Acc
s	0.9005	0.9056	0.9171	0.9925
m	0.8554	0.8608	0.8795	0.9888
n	0.6444	0.6803	0.7037	0.9738

由表 5 結果可知，YOLOv11s 與 YOLOv11m 於整體分類效能上皆顯著優於 YOLOv11n，顯示模型規模對焊點瑕疵分類任務之特徵學習能力具有明確影響。進一步觀察可發現，YOLOv11s 與 YOLOv11m 之間之性能差距相對有限，表示兩者皆能有效學習焊點瑕疵之關鍵特徵，並具備作為後續參數分析之基礎模型。

綜合而言，本節結果顯示模型規模對分類效能具有直接影響，其中中型與小型模型已可達成穩定之分類效果，因此後續實驗將以 YOLOv11s 與 YOLOv11m 作為主要候選模型進行進一步參數優化與分析。

然而此結果僅反映固定 learning rate = 0.001 條件下之模型表現，後續仍需透過不同學習率設定進一步評估模型於最佳化條件下之整體效能。

4-1-2 參數組合之結果分析

本節針對前述篩選後之候選模型（YOLOv11s 與 YOLOv11m），進一步探討不同學習率（learning rate）設定對焊點瑕疵分類效能之影響，以分析模型於不同超參數條件下之收斂特性、穩定性與辨識表現，並作為後續最佳模型選擇之依據。

由於學習率為影響深度學習模型收斂速度與最終效能之關鍵超參數，因此本研究分別設定 0.001、0.0009、0.0008 與 0.0007 等不同學習率進行實驗比較，以分析學習率對模型收斂速度與最終分類效能之影響，並於相同資料集切分方式與訓練條件下進行訓練，以確保不同設定之結果具備可比性。

評估指標包含 Defect Recall、Macro F1-score 與 Overall Accuracy，用以觀

察不同模型在各學習率條件下之分類效能變化與穩定性差異。

表 6、不同學習率設定之模型分類效能比較

Learning rate	Model	Defect Recall	Macro F1	Overall Acc
0.001	s	0.9005	0.9056	0.9925
0.001	m	0.8554	0.8608	0.9888
0.0009	s	0.7952	0.8310	0.9875
0.0009	m	0.7507	0.8036	0.9850
0.0008	s	0.8174	0.8406	0.9875
0.0008	m	0.7848	0.8042	0.9838
0.0007	s	0.7952	0.8117	0.9850
0.0007	m	0.8760	0.8813	0.9900

由表 6 結果可知，學習率設定對模型收斂行為與分類效能具有明顯影響，顯示超參數調整對焊點瑕疵辨識任務具有關鍵作用。

在較高學習率 (0.001 與 0.0009) 條件下，YOLOv11s 於整體評估指標上普遍優於 YOLOv11m，顯示在學習率較高時，小型模型具備較快收斂特性，且在本資料條件下能維持相對穩定之分類表現。然而隨學習率降低至 0.0008 時，兩者之性能差距開始縮小，整體分類效能逐漸趨於接近，顯示模型容量差異對結果之影響開始減弱。

當學習率進一步降低至 0.0007 時，YOLOv11m 在 Defect Recall、Macro F1-score 與 Overall Accuracy 等主要指標上表現最佳，顯示較大模型在較低學習率條件下，能更充分進行參數更新並學習細部焊點特徵資訊。

綜合上述結果可知，不同模型與學習率組合對模型效能具有顯著影響，其中 YOLOv11m 搭配 learning rate 0.0007 之設定，在本研究資料條件下呈現最佳整體表現。

因此，後續實驗將以 YOLOv11m 作為主要模型架構，並固定 learning rate 為 0.0007，以進一步驗證其於不同 batch size 與 image size 設定下之最佳化表現。

4-1-3 候選模型與最佳參數設定

本節整合前述模型規模分析 (4-1-1) 與學習率分析 (4-1-2) 之結果，進一步針對前述篩選後之 YOLOv11s 與 YOLOv11m 模型，於固定學習率 0.0007 條件下，結合不同 batch size 與 image size 之參數組合進行綜合評估，以建立最終模型選擇依據，並確認本研究之最佳訓練設定。

在模型評估過程中，本研究以 Defect Recall、Macro F1-score 與 Overall Accuracy 作為主要評估指標，以同時衡量模型於瑕疵辨識能力、整體分類表現與穩定性之綜合效能。

透過多組參數組合實驗，可進一步分析不同訓練配置對模型泛化能力與特徵學習能力之影響，各參數組合之實驗結果整理如表 7 所示。

表 7、不同參數組合之模型分類效能比較

Model	Batch	Image Size	Learning rate	Defect Recall	Macro F1	Overall Accuracy
m	16	320	0.0007	0.8760	0.8813	0.9900
s	16	320	0.0007	0.7952	0.8117	0.9850
m	32	320	0.0007	0.7310	0.7648	0.9800
s	32	320	0.0007	0.7021	0.7567	0.9813
m	32	640	0.0007	0.6624	0.7197	0.9788

由表 7 結果可知，在固定學習率 0.0007 條件下，不同 batch size 與 image size 組合對模型分類效能具有明顯影響，顯示資料批次大小與輸入解析度均會影響模型對焊點細部特徵之學習效果。

整體而言，當 batch size 設定為 16 且 image size 為 320 時，模型在 Defect Recall、Macro F1-score 與 Overall Accuracy 等指標上呈現較佳表現，顯示較小批次搭配中等解析度輸入，有助於模型在本研究資料條件下穩定學習焊點局部特徵與瑕疵差異。

進一步觀察模型規模差異可知，YOLOv11m 在多數參數組合下整體表現優於 YOLOv11s，尤其在瑕疵辨識相關指標上較為穩定，顯示較大模型在低學習率與適中 batch size 條件下，具備較佳之特徵擷取能力與泛化表現。

綜合上述分析結果，本研究於所有測試參數組合中，以 YOLOv11m 在 batch size 16、image size 320 及 learning rate 0.0007 之設定下達成最佳整體表現，因此選定該組合作為本研究之最終模型設定。

後續實驗將以此最佳模型為基礎，進一步進行 IC-level Good/NG 判定分析，以評估模型於實際 AOI 應用情境下之整體系統判定能力與實務可行性。

4-2 焊點層級分類模型效能分析

本節針對前述所選定之 YOLOv11 最佳模型與參數設定，於獨立測試資料集上進行焊點分類效能評估，以驗證模型於未參與訓練之資料上的泛化能力與穩定性表現。由第 4-1 節之實驗結果可知，本研究最終選定 YOLOv11m 作為主要模型架構，並採用 learning rate 0.0007、batch size 16 及 image size 320 之最佳參數組合，作為後續測試與分析之基礎。

本節評估以 pin-level（單一焊點影像）為基本單位，以驗證模型於局部焊點特徵辨識能力之表現，並以 Defect Recall、Macro F1-score、Balanced Accuracy 與 Overall Accuracy 作為主要評估指標，以綜合衡量模型於瑕疵辨識能力與整體分類表現之穩定性。

4-2-1 焊點層級整體分類效能分析

本節針對 YOLOv11 模型於測試資料集之整體分類效能進行分析，以評估其於焊點層級（pin-level）之辨識能力與分類穩定性。各模型之評估結果以 Defect Recall、Macro F1-score、Balanced Accuracy 及 Overall Accuracy 作為主要指標，

其結果如表 8 所示。

表 8、YOLOv11 模型於焊點層級 (pin-level) 分類效能比較

Model	Defect Recall	Macro F1	Balanced Accuracy	Overall Accuracy
YOLOv11s	0.7952	0.8117	0.8293	0.9850
YOLOv11m	0.8760	0.8813	0.8967	0.9900

由表 8 結果可知，YOLOv11m 在整體分類效能上明顯優於 YOLOv11s，尤其在 Defect Recall 與 Macro F1-score 等與瑕疵辨識能力高度相關之指標上提升較為顯著，顯示其對於少數瑕疵類別具有較佳之學習與辨識能力。

此外，兩模型之 Overall Accuracy 皆接近 0.99，顯示整體分類結果具有良好穩定性。然而，由於本研究資料具有明顯類別不平衡特性，Overall Accuracy 容易受到大量正常樣本影響，因此較能反映模型對少數類別表現之 Macro F1-score 與 Balanced Accuracy，在評估上具有更高參考價值。

因此，後續將於 4-2-2 進一步針對各瑕疵類別之 Precision、Recall 與 F1-score 進行細部分析，以探討模型於不同缺陷型態下之辨識差異。

4-2-2 各類別分類效能分析

本節針對 YOLOv11m 模型於測試資料集之各類別分類效能進行分析，以深入探討模型在不同焊點瑕疵類別間之辨識差異與限制。考量本研究資料具有類別不平衡特性，故進一步以 Precision、Recall 與 F1-score 分別評估各類別之分類表現，以更完整反映模型對不同缺陷型態之辨識能力。各類別之詳細分類結果如表 9 所示。

表 9、YOLOv11 模型於測試資料集之焊點分類結果

Class	Precision	Recall	F1-score	Support
少錫	0.5258	0.7391	0.6145	69
假焊	0.8673	0.8586	0.8629	99
多錫	1.0000	0.3542	0.5231	48
偏移	0.6667	0.4444	0.5333	54
正常	0.9996	1.0000	0.9998	19679
其他	0.5846	0.7451	0.6552	51

由表 9 結果可知，「假焊」類別具有較高之 Precision 與 Recall，顯示該類瑕疵具有較明顯且一致之視覺特徵，使模型能夠較穩定地進行辨識。

相較之下，「多錫」與「偏移」之 Recall 較低，顯示模型於此類瑕疵之漏判情形較為明顯，此現象可能與該類缺陷與其他瑕疵或正常焊點在局部形貌特徵上具有高度相似性有關，使模型較難有效區分。

此外，「少錫」與「其他」類別之 F1-score 相對較低，顯示模型對於特徵較細微或定義較不明確之瑕疵類別仍存在一定程度之混淆現象。

「正常」類別由於樣本數遠高於瑕疵類別，因此 Precision 與 Recall 幾乎達

到 1，顯示模型對正常焊點具有高度穩定之辨識能力。然而此結果亦反映出資料不平衡可能對整體評估指標造成影響，使高頻類別在統計上占有較大權重。

4-2-3 混淆矩陣結果分析

本節針對 YOLOv11m 模型於測試資料集之分類結果進行混淆矩陣分析，以進一步觀察模型於各類焊點瑕疵之誤判型態與類別間之混淆關係。混淆矩陣可呈現實際標籤與預測結果之對應分布，有助於補充整體評估指標所無法完整呈現之細部分類行為。模型之混淆矩陣結果如表 10 所示。

表 10、YOLOv11 於測試資料集之焊點分類混淆矩陣

	少錫	假焊	多錫	偏移	正常	其他	Recall
少錫	51	0	0	4	4	10	0.74
假焊	0	85	0	7	1	6	0.86
多錫	20	0	17	1	1	9	0.35
偏移	14	12	0	24	2	2	0.44
正常	0	0	0	0	19679	0	1.0
其他	12	1	0	0	0	38	0.75
Precision	0.53	0.87	1.0	0.67	0.99	0.59	Acc=0.99

由表 10 結果可知，「正常」類別具有極高之辨識準確性，大量樣本皆能正確分類，顯示模型對正常焊點之特徵學習相當穩定。

在瑕疵類別方面，「假焊」之辨識效果最佳，顯示其特徵較具一致性，因此較易與其他類別區分。相較之下，「多錫」與「偏移」類別之誤判情形較為明顯，其中部分樣本容易被錯誤分類至其他瑕疵類別或正常類別，顯示其局部特徵與其他類別之重疊程度較高。

整體而言，混淆矩陣結果與前述 Precision、Recall 分析趨勢一致，顯示模型對於特徵明確之瑕疵類別具有較佳辨識能力，而對於外觀差異較細微之類別仍存在一定分類困難。

4-2-4 測試情境設計與資料規模設定

本研究除訓練集與驗證集之外，另行建立獨立測試資料集，以作為最終模型效能評估之依據，確保評估結果不受訓練過程資料影響，並具備客觀性與泛化驗證意義。考量實際產線應用情境中，正常焊點數量通常遠高於瑕疵焊點，本研究特別設計多組不同規模之測試情境，以模擬不同產線批量條件下之資料不平衡程度。

在測試設計上，本研究固定 321 個瑕疵焊點樣本數量不變，並逐步增加正常焊點樣本數，以建立由低不平衡至高不平衡之測試環境，藉此觀察模型在不同資料分布條件下之穩定性變化。此設計可更貼近實務 AOI 檢測情境中「高良率、低瑕疵率」之特性，並用以評估模型於極端類別不平衡情境下之魯棒性（robustness）。

此外，本研究之測試單位以 IC 為基礎進行統計，每顆 IC 包含 8 個焊點（pin-level samples），因此各測試情境之總樣本數係由 IC 數量乘以固定焊點數換算而得，以確保不同情境間具有一致之結構基準。各測試情境之設計如表 11 所示。

表 11、不同測試情境之 IC 與 pin-level 資料規模配置

測試情境	總腳位數	IC 數	瑕疵腳數	正常腳數
T1	4000	500	321	3679
T2	4800	600	321	4479
T3	6400	800	321	6079
T4	8000	1000	321	7679
T5	12000	1500	321	11679
T6	16000	2000	321	15679
T7	20000	2500	321	19679

由表 11 結果可知，本研究透過固定瑕疵樣本數並逐步增加正常樣本數之方式，系統性構建不同程度之資料不平衡測試情境，使測試條件更貼近實際產線中高良率製程之資料分布特性。

透過上述測試情境設計，本研究可進一步分析模型在不同資料規模與不平衡程度下之穩定性與泛化能力，並作為後續 IC-level 判定分析之基礎。在 IC-level 評估中，將依據 pin-level 分類結果結合規則式整合判定機制，進行整體 Good / NG 推論，以評估模型於實務 AOI 應用情境下之可靠性。

4-3 IC 層級瑕疵判定結果

本研究之 IC-level 判定係建立於 pin-level 分類結果之基礎上，採用規則式整合推論機制（rule-based inference），而非額外訓練獨立之 IC 分類模型。具體而言，針對單一 IC 之八個焊點分類結果進行整合，當任一焊點被判定為瑕疵類別時，該 IC 即依據邏輯或規則（logical OR rule）判定為 NG；僅當八個焊點皆為正常類別時，該 IC 始判定為 Good。

在資料使用方面，本研究資料集共包含 8,843 顆穩壓 IC 影像，其中包含正常樣本與瑕疵樣本。由於原始 AOI 資料中瑕疵樣本數量有限，因此研究期間持續蒐集工廠提供之同型號瑕疵 IC 影像，並納入整體資料集建構。所有資料皆經接腳區域定位與焊點裁切後建立焊點資料集，並依第三章所述方式進行訓練、驗證與測試資料切分。為進行 IC-level 效能評估，本研究自測試資料集中獨立抽取 2,500 顆 IC 作為評估樣本，該子集合涵蓋正常與瑕疵 IC 之原始分布，並維持與實際產線資料相近之比例特性，以確保評估結果之代表性與公平性。

該 2,500 顆 IC 係自第 6001 至 8843 顆 IC 範圍內進行隨機抽樣取得，以確保測試資料與訓練及驗證資料完全獨立，避免資料洩漏（data leakage）並維持評估結果之客觀性。

基於上述 IC-level 判定方式，本研究以 YOLOv11m 模型之 pin-level 分類結

果為基礎，進一步進行 IC 層級 Good / NG 整合判定，以評估其於實際產線應用情境下之整體系統判定能力。

4-3-1 IC 層級判定示意

前述 3-5-3 節已說明本研究之 IC 層級判定規則與流程設計，因此本節不再重複方法細節，而著重說明模型於測試資料集之輸出呈現方式。

本研究於 IC 影像推論階段，首先利用前述接腳區域定位結果取得各焊點之位置資訊，並以邊界框（Bounding Box）標示於原始 IC 影像中，以呈現各焊點之空間分布情形。其後，將各焊點影像輸入 YOLOv11 分類模型進行瑕疵辨識，輸出對應之預測類別與信心值（Confidence Score），作為分類結果之參考依據。

在結果整合上，係依據既定 IC 層級判定規則，將同一顆 IC 之八個焊點分類結果進行彙整，當任一焊點被判定為瑕疵類別時，該 IC 最終判定為 NG；僅當八個焊點皆為正常類別時，該 IC 始判定為 Good。

此外，為提升結果之可視化呈現與判讀性，本研究將焊點分類結果與 IC 層級判定結果疊加於原始影像中，使檢測結果可同時呈現局部焊點資訊與整體元件品質狀態。為具體呈現上述輸出方式，其示意結果如圖 12 所示。




圖 12、IC-level 判定規則下單一接腳導致整體 NG 之案例示意圖

由圖 12 可觀察到，該 IC 之八個接腳中僅有單一接腳被判定為瑕疵類別，其餘接腳皆為正常類別。依據本研究之 IC 層級整合判定規則，當任一接腳被辨識為瑕疵時，整體 IC 即判定為 NG，因此該樣本最終結果為 NG。

此案例顯示，本研究之 IC-level 判定結果係由 pin-level 分類結果經規則式整合後所得，而非由獨立之整體分類模型直接輸出。因此，局部接腳之分類結果將直接影響最終 IC 之品質判定結果。在上述基本判定規則說明後，為補充說明 IC-level 判定結果於不同焊點異常情境下之表現，以下列舉不同瑕疵類型之實際檢

測結果作為說明。




圖 13、單一偏移接腳導致 IC 判定為 NG 之案例示意圖

圖 13 為接腳偏移瑕疵之 IC-level 判定案例。由結果可觀察到，雖然僅有單一接腳出現偏移情形，但系統仍可透過 pin-level 分類結果之整合，將整體 IC 判定為 NG。



圖 14、單一假焊接腳導致 IC 判定為 NG 之案例示意圖

由圖 14 可觀察到，該 IC 僅有單一接腳出現假焊瑕疵，其餘接腳皆判定為正常類別。依據本研究之 IC 層級判定規則，當任一接腳被判定為瑕疵類別時，整體 IC 即判定為 NG，因此該樣本最終結果為 NG。

綜合上述案例可知，本研究所提出之 IC 層級判定規則可穩定適用於不同類

型焊點異常，且最終判定結果係由 pin-level 分類結果經整合後所得。

4-3-2 IC 層級判定結果與模型效能比較

本節針對 YOLOv11s 與 YOLOv11m 兩種模型於 IC 層級 (IC-level) Good / NG 判定任務之實際表現進行分析，以評估模型於最終元件判定階段之整合能力。在測試資料集共 2,500 顆 IC 條件下，兩模型之 IC-level 混淆矩陣結果如表 12 與表 13 所示，且為進行模型間之直接比較，以下分別列出 YOLOv11s 與 YOLOv11m 之 IC-level 混淆矩陣結果。

表 12、YOLOv11s 於 IC-level 之混淆矩陣

	Pred OK	Pred NG
True OK	2190	0
True NG	4	306

表 13、YOLOv11m 於 IC-level 之混淆矩陣

	Pred OK	Pred NG
True OK	2190	0
True NG	8	302

依據測試結果顯示，YOLOv11s 模型於 2,500 顆 IC 中共正確判定 2,496 顆 IC，其中正常 IC (OK) 皆可正確判定，瑕疵 IC 中有 4 顆被誤判為 OK；YOLOv11m 則共正確判定 2,492 顆 IC，其中有 8 顆瑕疵 IC 被誤判為 OK。

整體 IC-level 準確率方面，YOLOv11s 為 99.84%(0.9984)，YOLOv11m 為 99.68% (0.9968)，兩者皆達 99% 以上之高準確率，且 YOLOv11s 略優於 YOLOv11m。

進一步觀察可發現，兩模型於 IC-level 之差異主要來自少數瑕疵樣本之漏判情形，整體結果仍維持高度一致性，顯示 IC-level 判定結果主要受 pin-level 分類結果影響。

綜合而言，YOLOv11m 雖於 pin-level 分類任務中表現較佳，但在 IC-level 整合判定情境下，兩模型皆能維持穩定之判定能力，顯示本研究所提出之 IC-level 判定規則具有良好穩定性與實務可行性。雖然 YOLOv11s 於 IC-level Accuracy 略高於 YOLOv11m，但本研究主要以 Defect Recall 與 Macro F1-score 作為模型選擇依據，考量 AOI 實際應用中對瑕疵檢出能力之需求，因此後續仍以 YOLOv11m 作為最佳模型進行分析與討論。

4-3-3 IC 誤判案例與原因分析

本節針對 IC 層級判定結果中之誤判案例進行分析，以探討模型於實際應用情境下之錯誤來源。

由 IC 層級混淆矩陣結果可知，整體誤判樣本數相對較少。進一步分析發現，IC 層級之錯誤主要源自 pin-level 分類結果之誤判傳遞效應。由於本研究之 IC 層級判定係採用「任一接腳為瑕疵即判定為 NG」之規則，因此當單一接腳於 pin-

level 階段發生誤判時，將直接影響 IC 層級之最終判定結果。

以實際案例為例，部分誤判案例來自外觀接近正常焊點之輕微缺陷樣本，例如少錫程度較輕微或焊點輪廓差異不明顯之情形，使模型於特徵判斷時產生分類不確定性。此外，不同瑕疵類別於局部影像特徵上存在部分相似性，例如焊點形貌或亮度分布接近之情況，亦可能導致 pin-level 分類錯誤。

為進一步說明 IC 層級誤判之形成原因，本研究選取具代表性之案例進行分析。首先，圖 15 為單一焊點誤判導致 IC-level 最終判定錯誤之案例。




圖 15、單一焊點誤判導致 IC 層級 NG 判定之案例示意圖

由圖 15 可觀察到，該 IC 實際標籤為正常（OK），然而其中一個焊點於 pin-level 分類中被誤判為瑕疵類別，使得依據本研究之 IC-level 判定規則（任一接腳為 NG 即判定整體 IC 為 NG），導致該 IC 最終被錯誤分類為 NG。

此結果顯示 IC-level 判定結果完全取決於 pin-level 分類輸出，因此單一接腳之誤判即可直接影響最終 IC-level 判定結果。

除上述導致 IC-level 最終判定錯誤之情形外，亦觀察到部分案例雖成功辨識主要瑕疵接腳，但仍出現少數正常接腳被誤判為瑕疵類別之現象。此類情形雖不一定影響最終 IC-level 判定結果，但仍反映模型於局部特徵辨識上之限制，其代表性案例如圖 16 所示。




圖 16、多重焊點誤判現象之案例示意圖

由圖 16 可觀察到，該 IC 中實際存在一隻多錫瑕疵接腳，因此整體 IC 應判定為 NG。然而於 pin-level 分類結果中，除該瑕疵接腳被正確辨識外，部分正常接腳亦被誤判為瑕疵類別。

推測此情形可能與正常焊點與瑕疵焊點在局部紋理、亮度分布或形貌特徵上具有相似性有關，因此造成模型產生誤判。

綜合上述案例可知，本研究之 IC 層級判定結果主要受 pin-level 分類準確性影響，而 pin-level 誤判將透過規則式整合直接反映於 IC-level 結果。此外，部分瑕疵與正常焊點在影像特徵上存在相似性，亦增加模型於局部分類之難度，此現象亦反映 AOI 影像於實務應用中仍具挑戰性。

4-4 綜合討論

本節針對前述模型於焊點層級（pin-level）與 IC 層級（IC-level）之實驗結果進行整體討論，並分析兩種評估層級之間的關聯性與差異性，以說明本研究方法於不同應用層級下之整體表現與穩定性。

此外，本節將進一步探討 pin-level 分類誤差對 IC-level 判定結果之影響程度，以及不同瑕疵類別在層級轉換過程中所呈現之變化情形，藉此分析模型於局部特徵辨識與整體元件判定之一致性。

4-4-1 模型效能整體分析

由 pin-level 與 IC-level 之實驗結果可知，不同評估層級下之模型表現趨勢存在差異，顯示單一焊點分類能力與整體 IC 判定效能之間並非呈現一對一對應關係。

此差異主要源自 IC-level 判定機制屬於多接腳整合式決策，其結果係依據所

有焊點之分類輸出透過規則式整合 (rule-based aggregation) 所得，而非模型直接學習之獨立輸出。因此，IC-level 結果本質上為 pin-level 分類結果經由系統層級推論所形成之結果。

此外，由於 IC-level 採用「任一焊點判定為瑕疵即判定為 NG」之邏輯或判定規則，使整體判定結果對局部分類誤差具有高度敏感性。因此，即使僅存在少量 pin-level 誤判，亦可能於 IC-level 層級產生放大效應，影響最終判定結果。

綜合而言，pin-level 與 IC-level 分別反映模型於「局部特徵辨識能力」與「元件層級整體判定能力」兩種不同層級之性能表現，其評估目的與意義並不相同，因此不宜僅以單一評估層級結果作為模型整體效能之唯一判斷依據。

4-4-2 焊點層級與 IC 層級結果比較分析

本研究為進一步比較不同評估層級間之差異，整理 pin-level 與 IC-level 之整體模型表現如表 14、Pin-level 與 IC-level 模型效能比較結果所示，以分析單一焊點分類效能與整體 IC 判定結果之關聯性。

表 14、Pin-level 與 IC-level 模型效能比較結果

評估層級	指標	YOLOv11s	YOLOv11m	說明
Pin-level	Macro F1	0.8117	0.8813	單腳分類能力
Pin-level	Recall	0.7952	0.8760	瑕疵辨識能力
Pin-level	Overall Acc	0.9850	0.9900	全部焊點分類
IC-level	Accuracy	0.9984	0.9968	最終 Good/NG 判定
IC-level	Error IC	4 / 2500	8 / 2500	IC 誤判數量

由表 14 可知，在 pin-level 評估中，YOLOv11m 於 Macro F1-score、Defect Recall 與 Overall Accuracy 等指標上均優於 YOLOv11s，顯示其於單一焊點特徵辨識能力方面具有較佳表現。

然而在 IC-level 整體判定結果中，兩模型之差異明顯縮小，皆可達 99% 以上之 Accuracy。雖然 YOLOv11s 於 IC-level Accuracy 略高於 YOLOv11m，但兩者差距僅為 0.16%，實際誤判數量差異亦僅為 4 顆 IC，顯示兩模型於系統層級判定能力上皆具有良好表現。

此外，由於 IC-level 判定採用「任一焊點判定為 NG，則整顆 IC 判定為 NG」之決策規則，因此少量焊點誤判即可能影響最終 IC 判定結果。此結果亦顯示，pin-level 之辨識能力與 IC-level 之最終判定結果並非完全線性對應，而會受到多接腳整合判定機制之影響。

綜合而言，pin-level 與 IC-level 分別反映「單點辨識能力」與「系統整合判定能力」，兩者評估目的有所不同。考量本研究主要目標為提升焊點瑕疵檢出能力，且 Defect Recall 與 Macro F1-score 為主要模型選擇依據，因此最終選擇於 Defect Recall 與 Macro F1-score 等主要評估指標中具有較佳表現之 YOLOv11m 作為本研究之最佳模型。

4-4-3 不同測試規模之穩定性分析

為驗證模型於不同產線批量條件下之穩定性，本研究針對 500 至 2500 顆 IC 之多種測試規模進行 IC-level 判定分析，以觀察資料規模變化對模型整體效能之影響。

其中表 15 為 YOLOv11s 之 IC-level 判定結果，表 16 為 YOLOv11m 之 IC-level 判定結果。

表 15、YOLOv11s 模型於不同產線批量條件下之 IC-level 判定結果

測試規模 (IC 數)	True OK → Pred OK	True OK → Pred NG	True NG → Pred OK	True NG → Pred NG	Accuracy
500	255	0	2	243	0.9960
600	361	0	2	237	0.9967
800	536	0	2	262	0.9975
1000	718	0	3	279	0.9970
1500	1214	0	2	284	0.9987
2000	1702	0	4	294	0.9980
2500	2190	0	4	306	0.9984

表 16、YOLOv11m 模型於不同產線批量條件下之 IC-level 判定結果

測試規模 (IC 數)	True OK → Pred OK	True OK → Pred NG	True NG → Pred OK	True NG → Pred NG	Accuracy
500	255	0	5	240	0.9900
600	361	0	4	235	0.9933
800	536	0	5	259	0.9938
1000	718	0	7	275	0.9930
1500	1214	0	6	280	0.9960
2000	1702	0	7	291	0.9965
2500	2190	0	8	302	0.9968

由表 15 與表 16 之結果可知，無論 YOLOv11s 或 YOLOv11m，於不同測試規模條件下之 IC-level Accuracy 皆維持於高水準區間，且整體趨勢相對穩定，未因 IC 數量增加而出現明顯下降。

此外，各測試規模下之 True NG 與 True OK 之判定分布亦呈現一致性，顯示模型於不同資料規模條件下之 IC-level 判定結果具備穩定性，未因樣本規模變化而產生明顯偏移。

整體而言，本研究所提出之 IC-level 判定方法在不同測試規模條件下均能維持一致之分類表現，顯示其具有良好之規模適應能力與穩定性，適用於不同產線批量檢測情境。

此外可觀察到，兩模型於 IC-level 之表現差異相對有限，顯示 IC-level 整合判定機制在一定程度上降低了 pin-level 分類差異對最終結果之影響。

4-4-4 模型差異與穩定性討論

綜合不同測試規模下之實驗結果可知，YOLOv11s 與 YOLOv11m 於 IC-level 判定任務中之整體表現趨勢高度一致，且兩者於各測試情境下之 Accuracy 皆維持於高水準且變動幅度極小。

此結果顯示，在 IC-level 多接腳整合判定機制下，模型規模所造成之差異於系統層級判定結果中已呈現一定程度之弱化，使不同模型在最終 IC 判定結果上具備相近之穩定性表現。

此外，雖然 NG 類別於不同測試規模下仍存在些微波動，但該變動未對整體 IC-level 判定結果造成顯著影響，顯示系統對局部分類誤差具有一定程度之容忍能力。

進一步而言，此穩定性主要來自 IC-level 判定機制之設計，即以「任一焊點判定為瑕疵即判定 IC 為 NG」之規則式整合方式，使單一 pin-level 分類誤差僅會在特定情況下影響最終判定結果，而不會隨資料規模增加而累積放大。

整體而言，本研究結果說明 IC-level 判定之穩定性主要來自於多接腳整合機制，使局部 pin-level 差異不會直接反映為整體 IC 判定結果之劇烈變動，因此在實務應用中，IC-level 層級之系統穩定性相較於單一 pin-level 分類結果更為關鍵。

4-4-5 實務應用可行性分析

本研究於 IC-level 測試中所達成之整體準確率約為 0.998，顯示模型於 IC 層級 Good / NG 判定任務中具備良好之整體判定能力。然而，考量 AOI 實際應用情境，模型評估除整體準確率外，仍須進一步考慮瑕疵檢出能力 (Defect Recall) 與漏檢風險。實際 AOI 產線之品質管理目標並非僅追求高準確率，而是降低不良品漏檢 (False Negative) 之風險，以避免瑕疵產品流入後續製程或出貨階段。

根據本研究資料統計結果，整體資料集共包含 8,843 顆穩壓 IC 影像，其中正常樣本占大多數，而瑕疵樣本數量相對有限。研究期間持續蒐集工廠提供之同型號瑕疵 IC 影像，並與原有 AOI 資料共同建立焊點瑕疵資料集，以增加瑕疵樣本之代表性。由於單一 IC 可能同時包含多個瑕疵焊點，因此瑕疵 IC 數量與瑕疵焊點數量並不具有一對一對應關係。本研究最終建立 321 個瑕疵焊點樣本，作為模型訓練與評估之依據。

在此高度不平衡之資料條件下，模型仍能維持穩定之分類表現。其中 YOLOv11m 於 Defect Recall 與 Macro F1-score 等指標上優於 YOLOv11s，顯示其對瑕疵焊點具有較佳之檢出能力。雖然 YOLOv11m 於部分案例中可能將同一顆 IC 內之部分正常焊點誤判為瑕疵類別，但實際觀察發現，其對於真正存在瑕疵之 IC 具有較高之檢出能力，可有效降低漏檢情形發生。

相較之下，YOLOv11s 雖具有較高之 IC-level 整體準確率，但仍存在少量瑕

疵焊點未被檢出之情況。由於實際 AOI 檢測流程中，誤判為瑕疵之樣本仍可透過人工複判進行確認，而漏檢則可能造成不良品流出，因此瑕疵檢出能力通常較整體準確率更具實務意義。

此外，本研究提出之 pin-level 至 IC-level 兩階段整合架構，除可提供單一焊點之缺陷資訊外，亦能進一步完成元件層級之品質判定。透過接腳區域定位、焊點分類與 IC 層級整合判定流程，可協助檢測人員快速定位異常焊點位置，提升後續人工複判與品質追蹤效率。

綜合實驗數據與實際檢測結果分析，本研究認為 YOLOv11m 雖可能增加部分過檢情形，但其較高之瑕疵檢出能力更符合實際產線品質管理需求，因此具備較高之實務應用價值與導入潛力。

第五章 結論

本研究以自動光學檢測 (AOI) 產線影像為基礎，建立接腳區域定位、單腳焊點影像生成、焊點瑕疵分類以及 IC 層級品質判定之完整檢測流程，並建構基於 YOLOv11 之穩壓 IC 焊點瑕疵辨識系統，以提升焊點缺陷檢測之自動化能力與實務應用價值。

首先，在資料建構階段，本研究透過接腳區域定位技術，自原始穩壓 IC 影像中自動擷取各接腳焊點區域，並建立單腳焊點影像資料集。藉由自動化 ROI 定位與焊點裁切流程，不僅降低大量人工標註與裁切作業所需之時間成本，亦提升資料建構之一致性與可靠性，作為後續深度學習模型訓練之基礎。

在 pin-level 焊點分類任務中，本研究比較 YOLOv11n、YOLOv11s 與 YOLOv11m 等不同模型規模，並進一步分析不同學習率、批次大小及輸入影像尺寸等訓練參數對模型效能之影響。實驗結果顯示，YOLOv11m 於 Defect Recall 與 Macro F1-score 等主要評估指標上具有最佳表現，顯示其具備較佳之局部特徵擷取能力與瑕疵檢出能力，能有效學習不同焊點缺陷之影像特徵。

在 IC-level 整合判定方面，本研究提出「任一接腳異常即判定為 NG」之規則式整合方法，將八個焊點之分類結果轉換為元件層級之品質判定結果。實驗結果顯示，YOLOv11s 與 YOLOv11m 於 IC-level 皆可達 99.7% 以上之整體準確率，顯示本研究所提出之兩階段判定架構可有效完成由焊點層級至元件層級之品質判定。

然而，進一步分析實際檢測結果可發現，YOLOv11m 雖可能產生部分正常焊點被誤判為瑕疵之情形，但其對瑕疵焊點具有較高之檢出能力，可有效降低漏檢風險；相較之下，YOLOv11s 雖具有略高之 IC-level 整體準確率，但仍存在少量瑕疵焊點未被檢出之情形。考量實際 AOI 品質管理以避免不良品流出為首要目標，因此本研究認為 Defect Recall 較整體 Accuracy 更能反映模型於實務應用之價值。

此外，本研究透過 500 至 2500 顆 IC 之不同測試規模進行穩定性驗證，結果顯示模型於不同資料規模下皆能維持穩定之判定表現，顯示本方法具備良好之規模適應能力與實務應用潛力。

在實務應用層面，本研究進一步觀察模型實際檢測結果後發現，YOLOv11m 雖然於部分樣本中可能將同一顆 IC 內之正常焊點誤判為瑕疵類別，但其對瑕疵焊點具有較高之檢出能力，可有效降低漏檢風險。實際檢測結果顯示，當 IC 存在瑕疵焊點時，YOLOv11m 通常能成功標示出異常焊點，並提供檢測人員進一步確認之依據；相較之下，YOLOv11s 雖具有較高之整體準確率，但仍存在少量瑕疵樣本未被檢出之情形。考量實際 AOI 系統之品質管理目標在於避免不良品流出，因此相較於過檢 (False Positive)，漏檢 (False Negative) 所造成之影響更為嚴重。綜合實驗數據與實際檢測結果分析，本研究認為 YOLOv11m 較符合實際產線之品質管制需求。

綜合而言，本研究成功建立一套結合接腳區域定位、焊點瑕疵辨識與 IC 層級品質判定之檢測方法，驗證 YOLOv11 模型於焊點缺陷辨識任務之可行性，並證明透過 pin-level 至 IC-level 之兩階段判定架構，可有效支援實際 AOI 產線之品質檢測需求，具備良好之實務應用價值。

未來研究可進一步擴充不同封裝型態與更多實際產線瑕疵樣本，提升模型於多樣化製程條件下之泛化能力。此外，亦可導入更精細之缺陷定位技術與即時 AOI 系統整合機制，進一步提升檢測系統於實際產線環境下之穩定性與應用效益。

參考文獻

- [1] I-Chun Chen, Rey-Chue Hwang, Huang-Chu Huang. “PCB Defect Detection System Based on CNN and YOLOv3 for Improving AOI Misjudgment and Detection Accuracy,” *Applied Sciences*, MDPI, 2022.
- [2] Kaihua Zhang, Haikuo Shen. “Deep Learning-Based Semantic Segmentation Combined with Rule-Based Algorithm for Rapid PCBA AOI Defect Detection in Production Lines,” *IEEE/ASME Journal of Automation Science and Engineering*, 2024.
- [3] Bernardo Montoya Magaña, Óscar Hernández-Uribe, Leonor Adriana Cárdenas-Robledo, Jose Antonio Cantoral-Ceballos. “Deep Learning-Based Secondary Inspection System for AOI PCB Defect Detection,” *Processes*, MDPI, 2023.
- [4] Zhiduan Ni, Yeonhee Kim. “PCB Defect Detection Using YOLOv5 and Data Augmentation for Improved AOI Performance,” *Electronics*, MDPI, 2024.
- [5] Hao Yan, Hong Zhang, Fengyu Gao, Huaqin Wu, Shun Tang. “An Ensemble Method Based on YOLOv2 and Faster R-CNN for PCB DIP Process Defect Detection,” *IEEE Conference Publication*, IEEE Xplore.
- [6] Gaoshang Xiao, Shuling Hou, Huiying Zhou. “Improved YOLOv8s for Small-Scale PCB Defect Detection with Enhanced Efficiency and Accuracy,” *Sensors*, MDPI, 2024.
- [7] Aryan Sharma, Manan Agrawal, Parikshit Sardeshpande, Aditya Gupta, Ayaan Pasha, Richa R. Khandelwal. “PCB Defect Detection with Limited Annotation Using Semi-Supervised Learning,” *Sensors*, MDPI, 2023.
- [8] Chien-Yi Huang, I-Chen Lin, Yuan-Lien Liu. “PCB Defect Detection Framework Based on Generative Model and Swin Transformer,” *Sensors*, MDPI, 2024.
- [9] Yang Li, Xiao Wang, Zhifan He, Ze Wang, Ke Cheng, Sanchuan Ding, Yijing Fan, Xiaotao Li, Yawen Niu, Shanpeng Xiao, Zhenqi Hao, Bin Gao, Huaqiang Wu. “Multi-Scale PCB Surface Defect Detection Using Deep Learning Models,” *Sensors*, MDPI, 2025.
- [10] Thi Tram Anh Pham, Do Kieu Trang Thoi, Hyohoon Choi, Suhyun Park. “SolDef_AI Dataset and Mask R-CNN-Based PCB Solder Defect Detection,” *Applied Sciences*, MDPI, 2023.
- [11] Yulong Liu, Hao Wu, Youzhi Xu, Xiaoming Liu, Xiujuan Yu. “Deep Learning-Based PCB and Solder Joint Defect Detection for Industrial Applications,” *IEEE Access*, IEEE, 2024.
- [12] Youzhi Xu, Hao Wu, Yulong Liu, Xing Zhang. “CDI-YOLO: Improved

YOLOv7-Tiny for High-Accuracy and Lightweight PCB Defect Detection,” *Scientific Reports*, Nature, 2024.

- [13] Gianmauro Fontana, Maurizio Calabrese, Leonardo Agnusdei, Gabriele Papadia, Antonio Del Prete. “A Systematic Review of Deep Learning Methods for Electronic Assembly Defect Detection,” *Applied Sciences*, MDPI, 2024.